

ANÁLISIS EXPLORATORIO DE DATOS INICIAL

Sprint 1

Proyecto: Identificación de Polos de Alta Productividad
y Sectores en Reconversión mediante Clustering

Equipo Nro. 3 | Tecnicatura Superior en Ciencia de Datos e IA

Fecha: 10/05/2026

Introducción

El presente documento corresponde al Análisis Exploratorio de Datos (EDA) inicial del Sprint 1. El objetivo es caracterizar los datasets disponibles: registrar su estructura, tipos de variables, calidad de datos (nulos, vacíos, inconsistencias) y obtener observaciones preliminares que orienten el trabajo de los próximos sprints.

Pregunta de investigación: Es posible identificar grupos de sectores industriales que, a pesar de tener baja capacidad instalada, muestran una alta eficiencia o reconversión hacia el valor agregado mediante el uso de tecnología?

Datasets analizados:

1. IPI Manufacturero — INDEC
2. UCII (Utilización de Capacidad Instalada Industrial) — INDEC
3. Fichas Sectoriales — CEP XXI / Ministerio de Economía
4. Exportaciones por sector — CEP XXI / Ministerio de Economía

Dataset 1 — IPI Manufacturero (INDEC)

Información del dataset

Atributo	Valor
Dataset	IPI Manufacturero — divisiones y subclases CLNAE 2004
Fuente	Instituto Nacional de Estadística y Censos (INDEC)
Archivo	sh_ipi_manufacturero_2026.xls — hoja Cuadro 2
Registros (filas)	123
Variables (cols.)	88 (fecha, año, mes + 85 índices sectoriales)
Periodo	Enero 2016 — marzo 2026
Frecuencia	Mensual
Unidad de medida	Numero índice (base 2004 = 100)

Tipos de variables

Variable	Tipo de dato	Descripción
fecha	Fecha	Primer día de cada mes (fecha de referencia)
año	Numero entero	Año de la observación
mes	Texto	Nombre del mes en español
IPI Manufacturero	Numero decimal	Índice general de producción industrial (base 2004=100)
Alimentos y bebidas	Numero decimal	Índice de producción — división alimentos y bebidas
Textiles	Numero decimal	Índice de producción — divisiones textiles
Papel y cartón	Numero decimal	Índice de producción — división papel y cartón
Refinación del petróleo	Numero decimal	Índice de producción — división refinación
Sustancias químicas	Numero decimal	Índice de producción — división química
Industria automotriz	Numero decimal	Índice de producción — división automotriz
... (79 subclases más)	Numero decimal	Índice de producción por subclase CLNAE 2004

Calidad de datos - Valores nulos

Variable	Nulos / Vacíos	% del total	Interpretación
Preparación de hojas de tabaco	43 de 123	35,0%	Serie discontinuada por INDEC a partir de 2019.
Neumáticos	2 de 123	1,6%	Valores faltantes puntuales. Sin impacto relevante.
Otros productos de caucho	2 de 123	1,6%	Valores faltantes puntuales. Sin impacto relevante.

Las 85 columnas restantes no presentan valores nulos.

Inconsistencias y problemas detectados

- **Datos provisionales:** Los últimos 3 a 6 meses de la serie están marcados con asterisco (*) en el archivo original, indicando datos provisionales sujetos a revisión por INDEC.
- **Campo año incompleto:** El campo año solo aparece en la fila de enero; los demás meses tienen esa celda vacía. Requiere relleno hacia abajo antes de procesar.
- **Encabezado de dos niveles:** El archivo tiene un encabezado de dos niveles (fila de códigos CLANAE + fila de nombres de sector) que requiere procesamiento previo para obtener una tabla limpia.
- **Granularidad diferente al UCII:** El IPI tiene ~85 subclases CLANAE mientras la UCII reporta solo 12 bloques. No hay correspondencia directa 1:1 entre ambos datasets.

Observaciones iniciales

- Mínimo del periodo: 80,4 puntos en abril 2020 (caída por COVID-19).
- Máximo del periodo: 143,0 puntos en agosto 2017.
- Promedio 2016-2026: 123,4 puntos.
- Caída pronunciada en 2020 (promedio anual 109,1) con recuperación en 2021-2022 (126,2 y 131,5). Nueva contracción desde 2024 (promedio 117,0).
- Los sectores de exportación (petróleo, alimentos) mantienen índices sistemáticamente más altos que los orientados al mercado interno.

Dataset 2 — UCII (INDEC)

Información del dataset

Atributo	Valor
Dataset	Utilización de la Capacidad Instalada Industrial — NG y bloques sectoriales
Fuente	Instituto Nacional de Estadística y Censos (INDEC)
Archivo	sh_capacidad_04_26.xls — hoja UCI - NG y bloques
Registros (filas)	110
Variables (cols.)	16 (fecha, año, mes + Nivel general + 12 bloques industriales)
Periodo	Enero 2017 — febrero 2026
Frecuencia	Mensual
Unidad de medida	Porcentaje (%) — variable derivada: Capacidad Ociosa = 100 - UCII

Tipos de variables

Variable	Tipo de dato	Descripción
fecha	Fecha	Primer día de cada mes (fecha de referencia)
año	Numero entero	Año de la observación
mes	Texto	Nombre del mes en español
Nivel general	Numero decimal	Porcentaje promedio de utilización de toda la industria
Productos alimenticios y bebidas	Numero decimal	% de utilización de la capacidad instalada del bloque
Productos del tabaco	Numero decimal	% de utilización de la capacidad instalada del bloque
Productos textiles	Numero decimal	% de utilización de la capacidad instalada del bloque
Papel y cartón	Numero decimal	% de utilización de la capacidad instalada del bloque
Edición e impresión	Numero decimal	% de utilización de la capacidad instalada del bloque
Refinación del petróleo	Numero decimal	% de utilización de la capacidad instalada del bloque
Sustancias y productos químicos	Numero decimal	% de utilización de la capacidad instalada del bloque
Productos de caucho y plástico	Numero decimal	% de utilización de la capacidad instalada del bloque

Productos minerales no metálicos	Numero decimal	% de utilización de la capacidad instalada del bloque
Industrias metálicas básicas	Numero decimal	% de utilización de la capacidad instalada del bloque
Industria automotriz	Numero decimal	% de utilización de la capacidad instalada del bloque
Metalmecánica excluida industria automotriz	Numero decimal	% de utilización de la capacidad instalada del bloque

Calidad de datos

Valores nulos

Variable	Nulos / Vacíos	% del total	Interpretación
Productos del tabaco	1 de 110	0,9%	Valor faltante puntual. Sin impacto relevante.
Industria automotriz	1 de 110	0,9%	Valor faltante puntual. Sin impacto relevante.

Las 14 columnas restantes no presentan valores nulos.

Inconsistencias y problemas detectados

- **Campo Periodo mixto:** La columna Periodo del archivo original mezcla marcadores de año ('Año 2016') con nombres de mes ('Enero*', 'Febrero*'). Requiere un procesamiento específico para separar ambos.
- **Datos provisionales:** Los meses con asterisco (*) son datos provisionales sujetos a revisión por INDEC.
- **256 columnas, solo 14 con datos:** El archivo tiene 256 columnas en total; solo las primeras 14 contienen datos. El resto son columnas vacías (reservadas?).
- **Granularidad menor al IPI:** La UCII reporta 12 bloques frente a las 85 subclases del IPI. Esto limita el cruce directo entre ambos datasets sin una tabla de equivalencias.

Observaciones iniciales

- Nivel general promedio del periodo (2017-2026): 61,5% — capacidad ociosa promedio: 38,5%.
- Mínimo histórico: 42,0% en abril 2020 (COVID-19). Máximo: 69,6% en agosto de 2022.
- Sectores con mayor utilización de capacidad: Refinación del petróleo (78,0%), Industrias metálicas básicas (72,6%), Papel y cartón (72,0%).
- Sectores con mayor capacidad ociosa: Industria automotriz (53,5% ociosa), Metalmecánica (51,3%), Textiles (50,4%).
- La brecha entre el sector de mayor y menor utilización supera los 30 puntos porcentuales, lo que valida la hipótesis del proyecto.

Dataset 3 — Fichas Sectoriales (CEP XXI)

Información del dataset

Atributo	Valor
Dataset	Fichas Sectoriales — indicadores económicos por sector productivo
Fuente	Centro de Estudios para la Producción XXI — Ministerio de Economía
Archivo	fichas_sectoriales_CEP_XXI.csv
Registros (filas)	125.259
Variables (cols.)	14
Formato	Formato largo: una fila por combinación sector x año x indicador
Sectores únicos	48 sectores productivos de la economía argentina
Indicadores únicos	121 indicadores (IPI, exportaciones, empleo, productividad, etc.)
Periodo	2002 — 2021
Frecuencia	Anual

Tipos de variables

Variable	Tipo de dato	Descripción
anio	Numero entero	Año de la observación
id_sector_productivo	Texto	Código identificador del sector (ej.: C_15)
nombre_sector_productivo	Texto	Nombre completo del sector productivo
nombre_variable	Texto	Nombre del indicador (ej.: IPI.base04, TOT_PUESTOS)
valor	Numero decimal	Valor numérico del indicador para ese sector y año
unidad_medida	Texto	Unidad en que se expresa el valor (índice, cantidad, %)
Viajes_Y_Turismo	Texto	Filtro de turismo — vacío en la mayoría de las filas (97,6%)
concepto_desc	Texto	Descripción adicional del concepto — vacío en mayoría (93,7%)
Socio	Texto	Socio comercial — aplica solo a filas de comercio exterior (92,2%)
ADUANA	Texto	Aduana de salida — aplica solo a exportaciones (97,2%)

USO_ECONOMICO	Texto	Uso económico del bien — aplica solo a comercio exterior (96,8%)
Producto	Texto	Producto exportado — aplica solo a filas de comercio exterior (98,3%)
Provincia	Texto	Provincia — aplica solo a indicadores con desagregación geográfica (92,4%)
Macrobloque	Numero entero	Agrupación del sector en uno de los macrobloques CEP XXI

Calidad de datos

Valores nulos

Variable	Nulos / Vacíos	% del total	Interpretación
valor	311 de 125.259	0,2%	Nulos reales en el campo de valor numérico.
Viajes_Y_Turismo	122.219 de 125.259	97,6%	NA estructural — columna contextual de turismo.
Producto	123.092 de 125.259	98,3%	NA estructural — aplica solo a filas de exportación.
ADUANA	121.752 de 125.259	97,2%	NA estructural — aplica solo a filas de exportación.
USO_ECONOMICO	121.277 de 125.259	96,8%	NA estructural — aplica solo a comercio exterior.
concepto_desc	117.413 de 125.259	93,7%	NA estructural — descripción contextual.
Provincia	115.720 de 125.259	92,4%	NA estructural — solo para indicadores geográficos.
Socio	115.538 de 125.259	92,2%	NA estructural — solo para indicadores de comercio exterior.

NOTA: El alto porcentaje de NA en las columnas contextuales es estructural y esperado. Estas columnas solo aplican a filas específicas (registros de comercio exterior, desagregación geográfica). Para el clustering se usarán únicamente: año, nombre_sector_productivo, nombre_variable, valor.

Inconsistencias y problemas detectados

- **Formato largo:** Los 125.259 registros representan combinaciones sector x año x indicador. Para el análisis de clustering debe pivotarse para obtener una fila por sector-año.
- **Heterogeneidad de unidades en valor:** La columna valor contiene valores de distinta naturaleza (índices, cantidades, porcentajes, millones de pesos) según el indicador. No son comparables sin filtrar previamente por nombre variable.
- **Brecha temporal:** El dataset cubre hasta 2021 mientras IPI y UCII llegan a 2026. Hay un desfase de 4 a 5 años en el extremo superior del periodo.

Observaciones iniciales

- 48 sectores productivos y 121 indicadores disponibles.
- Solo 311 nulos reales en el campo valor (0,2%).
- Indicadores clave para el proyecto disponibles en el dataset: IPI.base04 (846 registros), TOT_PUESTOS (846), EXPORTACIONES_FOB (532), VAB_PCONST_2004 (846), PRODUCTIVIDAD-PUE (846), M_SERVICIOS (1.506).
- Las columnas contextuales con NA estructural (92-98%) no representan un problema de calidad — son filtros que solo aplican a tipos específicos de indicador.

Dataset 4 — Exportaciones por sector (CEP XXI)

Información del dataset

Atributo	Valor
Dataset	Valores exportados FOB por sector de actividad económica
Fuente	Centro de Estudios para la Producción XXI — Ministerio de Economía
Archivo	exportaciones_CEP_XXI.csv
Registros (filas)	14.177
Variables (cols.)	3 (clae2, fecha, total_fob)
Periodo	Enero 2007 — noviembre 2023
Frecuencia	Mensual
Sectores CLAE2	85 códigos de actividad económica únicos
Unidad de medida	Pendiente confirmación de moneda (pesos o dólares FOB)

Tipos de variables

Variable	Tipo de dato	Descripción
clae2	Numero entero	Código de actividad económica a 2 dígitos — identifica el sector exportador
fecha	Fecha	Primer día del mes (fecha de referencia)
total_fob	Numero entero	Valor total exportado FOB en el periodo

Calidad de datos - Valores nulos

El dataset no presenta valores nulos en ninguna de sus 3 columnas. Es el dataset más limpio del conjunto analizado.

Inconsistencias y problemas detectados

- **Valores negativos en total_fob:** Se detectaron valores negativos en total_fob (valor mínimo: -99). Puede corresponder a devoluciones o ajustes contables. Requiere verificación.

- **Moneda sin confirmar:** No está documentado si total_fob está en pesos corrientes, dólares o millones. Requiere verificación en la metodología del CEP XXI antes de usar en el análisis.
- **Códigos CLAE2 sin etiqueta:** El dataset contiene solo el código numérico CLAE2. Para interpretarlo se necesita una tabla de equivalencias CLAE2 - nombre de sector.
- **Sin equivalencia con bloques INDEC:** Los 85 códigos CLAE2 no se mapean directamente a los 12 bloques de la UCII ni a los 48 sectores de las Fichas Sectoriales. Se necesita tabla de equivalencias.
- **Periodo parcial en 2023:** El último mes disponible es noviembre 2023 (sin diciembre). El año 2023 está incompleto para análisis anuales.

Observaciones iniciales

- El top 5 de sectores concentra el 76,1% del total exportado en todo el periodo.
- El sector CLAE2 10 (industria alimenticia / agroindustria) representa el 42,6% del total acumulado.
- Alta asimetría en la distribución: pocos sectores concentran la mayor parte del valor exportado.
- La distribución muy concentrada en pocos sectores es clave para identificar los Polos de Alta Productividad del proyecto.

Resumen Consolidado — Los 4 Datasets

Estado de los datasets al cierre del Sprint 1:

Dataset	Fuente	Registros	Columnas	Vars. núm..	Vars. texto	Vars. fecha	Periodo	Nulos relevantes
IPI Manufacture ro	INDEC	123	88	86	1	1	2016-2026	3 cola con nulos (1 sector 35%)
UCII	INDEC	110	16	13	1	1	2017-2026	2 bloques (0,9% c/u)
Fichas Sectoriales	CEP XXI	125.259	14	2	12	0	2002-2021	311 nulos en valor (0,2%)
Exportaciones	CEP XXI	14.177	3	2	0	1	2007-2023	Sin nulos / valores negativos

Visualizaciones

Las siguientes visualizaciones fueron generadas en Power BI a partir de los datasets procesados.

Gráfico 1 — Evolución del IPI Manufacturero (2016-2026)

Serie temporal del IPI nivel general. Muestra la tendencia, la caída por COVID-19 en 2020 (mínimo: 80,4 en abril 2020) y la recuperación posterior hasta 2022. La línea de referencia indica la base 2004=100.

Evolución del IPI Manufacturero (2016-2026)




Gráfico 2 — UCII promedio por bloque industrial (2017-2026)

Gráfico de barras con el promedio de UCII de cada bloque. Refinación del petróleo lidera con 78% de utilización; Industria automotriz es el de menor utilización con 46,5% (53,5% de capacidad ociosa).

UCII promedio por bloque industrial (2017-2026)





Gráfico 3 — Top 15 sectores exportadores por valor FOB acumulado (2007-2023)

Barras horizontales con los 15 sectores CLAE2 de mayor valor exportado acumulado. El top 5 concentra el 76,1% del total. CLAE2 10 representa el 42,6% por sí solo.



Hallazgos Iniciales

- **Asimetría estructural confirmada en UCII:** Refinación del petróleo opera al 78% de capacidad en promedio; Industria automotriz al 46,5%. La brecha supera los 30 puntos porcentuales, lo que valida directamente la hipótesis del proyecto.
- **COVID-19 identificable en ambas series INDEC:** Tanto IPI como UCII registran su mínimo histórico en abril 2020. La recuperación fue heterogénea: sectores exportadores se recuperaron más rápido que los orientados al consumo interno.
- **Capacidad Ociosa computable directamente:** Con la UCII disponible se puede calcular Capacidad Ociosa = $100 - UCII$ para los 12 bloques industriales. Esta es la variable central del modelo de clustering.
- **Alta concentración exportadora:** 5 sectores CLAE2 concentran el 76,1% de las exportaciones. Esta concentración es clave para identificar los Polos de Alta Productividad.
- **Problema de granularidad entre datasets:** IPI (~85 subclases), UCII (12 bloques), Fichas Sectoriales (48 sectores) y Exportaciones (85 códigos CLAE2) tienen distinto nivel de agregación. Se necesita una tabla de equivalencias antes de integrarlos.
- **Brecha temporal en Fichas Sectoriales:** Las Fichas Sectoriales cubren hasta 2021 mientras IPI y UCII llegan a 2026. Hay que decidir el periodo común para el clustering.

Preguntas que Surgen del EDA Inicial

- **Granularidad del clustering:** A qué nivel de agregación va a trabajar el modelo: 12 bloques INDEC, 48 sectores CEP XXI, o un nivel intermedio? Esto define que datasets se pueden integrar directamente.
- **Tabla de equivalencias entre datasets:** Como se construye la correspondencia entre los bloques UCII (INDEC), los sectores de Fichas Sectoriales (CEP XXI) y los códigos CLAE2 (Exportaciones)?
- **Moneda y delectación en Exportaciones:** El campo total fob de Exportaciones está en pesos corrientes o en dólares? Se necesita deflactar para comparar entre años?
- **Variable SBC:** Que variable de las Fichas Sectoriales representa mejor los Servicios Basados en el Conocimiento (SBC): M_SERVICIOS, X_SERVICIOS, o existe un dataset específico?
- **Periodo de análisis para el clustering:** Se usará el periodo completo disponible o se acotará a 2017-2021 donde todos los datasets se solapan?
- **Tratamiento del sector tabaco:** El sector tabaco en IPI tiene 35% de datos faltantes. Se excluye del análisis o se imputa?